Código de experimentación base con MLflow

Francisco Vicente Eugenio Ponce · A01840479
TC5061 · Actividad individual

Análisis de resultados

Se migró la regresión logística del notebook a un script con funciones para carga, limpieza, partición, preprocesamiento, entrenamiento y evaluación. Se conservaron las 23 variables del baseline y sus filtros: 119,390 reservas originales se redujeron a 87,208. La imputación, el escalado y la codificación se ajustaron solo con entrenamiento.

Se usaron 52,324 reservas para entrenamiento, 17,442 para validación y 17,442 para prueba, con estratificación y semilla 42. Las siete configuraciones distintas y una repetición se registraron bajo TC5061_Hoteles_Logistica_Experimentacion. El criterio de selección fue F1 de validación, con umbral fijo de 0.5; la prueba se consultó después de elegir el modelo.

La mejor configuración por ese criterio fue **04_balanced: C=1, class_weight=balanced, tol=0.0001 y max_iter=1000**. Logró F1=0.5651, precisión=0.4698, recall=0.7090 y ROC-AUC=0.7696 en validación. El mismo modelo guardado, sin reentrenamiento, obtuvo F1=0.5665 y ROC-AUC=0.7770 en prueba.

El hiperparámetro más influyente sobre F1 fue **class_weight**: al cambiar únicamente de none a balanced, F1 subió de 0.4689 a 0.5651 (+0.0962) y recall de 0.3499 a 0.7090, pero la precisión bajó de 0.7105 a 0.4698. El ROC-AUC apenas cambió (0.7691 a 0.7696): no se observó una mejora apreciable del ordenamiento de las predicciones. El beneficio aparece en el equilibrio precisión-recall a umbral 0.5. El balanceo modifica la función de pérdida y puede cambiar los coeficientes; no equivale necesariamente a mover solo el umbral.

C tuvo un efecto pequeño en todo el rango 0.01-100: el rango de F1 fue 0.0107 sin balanceo y 0.0028 con balanceo. Aumentar tol a 0.01 redujo las iteraciones de 60 a 8; F1 subió 0.0071, pero ROC-AUC cayó 0.0064. No hubo una mejora general de las métricas.

Las limitaciones son una sola partición y semilla, ausencia de validación temporal y posible información tardía en booking_changes o peticiones especiales. Eliminar duplicados puede excluir reservas grupales legítimas. La prueba coincide con la usada en la semana anterior: no es evidencia completamente nueva. Las diferencias pequeñas de C no demuestran superioridad estadística. El balanceo detecta más cancelaciones a costa de falsas alarmas; antes de usarlo se requieren costos de negocio y datos posteriores.

Reproducibilidad, ejecución y repositorio

Repositorio individual: https://github.com/FranciscoEP/TC5061-Experimentacion-MLFlow-A01840479

Python 3.13.5; versiones fijadas en requirements.txt. Semilla 42 en Python, NumPy, las dos particiones y el modelo; cálculo numérico limitado a un hilo. La repetición obtuvo métricas y probabilidades exactamente iguales (diferencia máxima=0). Se verificaron particiones disjuntas y la carga del pipeline registrado. El hash SHA-256 del CSV y los índices de partición quedan registrados en MLflow.

Comandos desde la carpeta del proyecto (tras instalar requirements.txt y colocar el CSV según README):

python train.py

python train.py --class-weight balanced

python run_experiments.py

python finalize_results.py

mlflow ui --backend-store-uri sqlite:///mlflow.db --port 5001

El segundo comando reproduce los hiperparámetros elegidos: los valores por defecto son C=1, tol=0.0001, max_iter=1000 y seed=42.

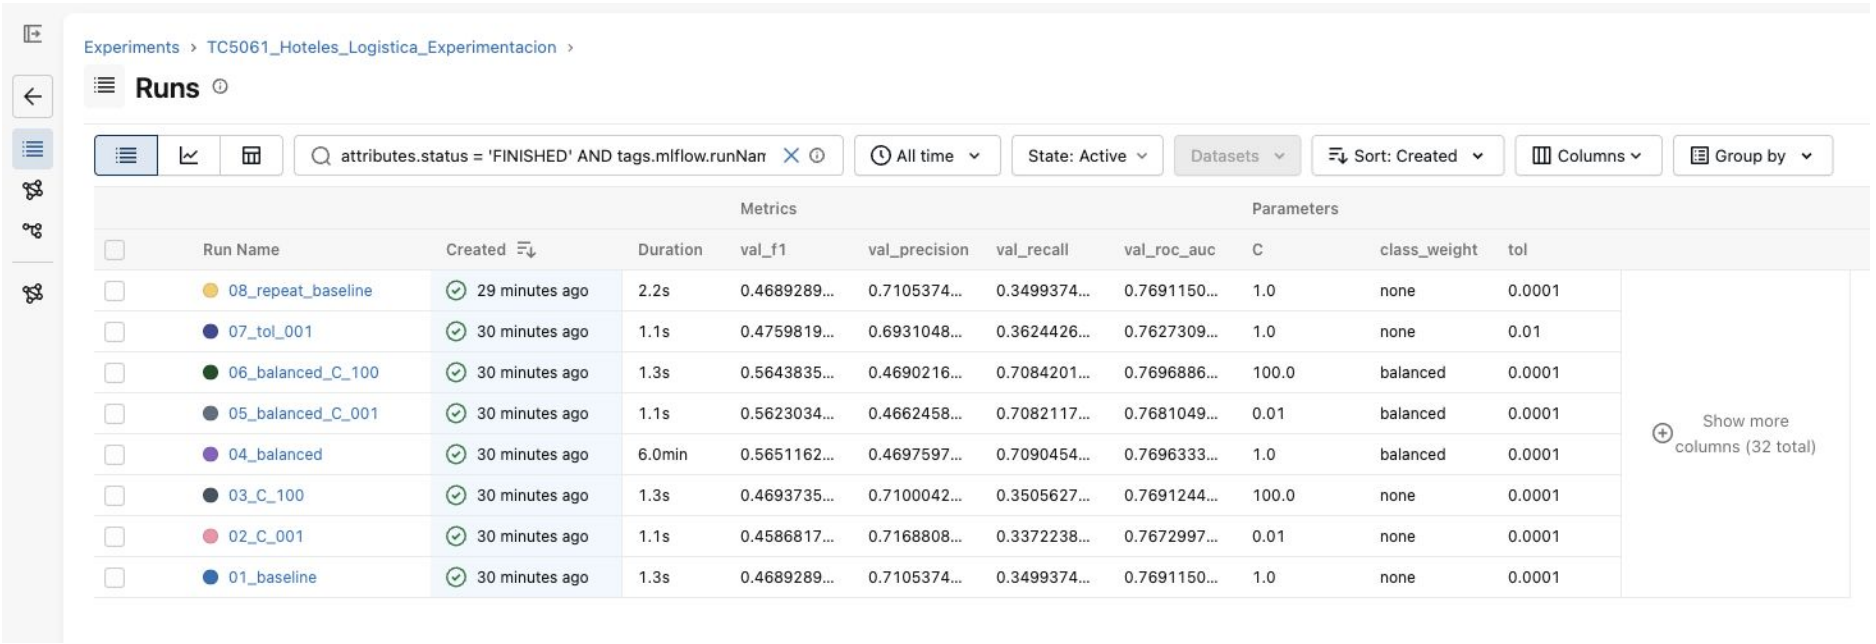
Tabla de validación (métricas redondeadas)

Corrida	C	Peso	tol	F1	Recall	AUC
01	1	none	0.0001	0.4689	0.3499	0.7691
02	0.01	none	0.0001	0.4587	0.3372	0.7673
03	100	none	0.0001	0.4694	0.3506	0.7691
04	1	balanced	0.0001	0.5651	0.7090	0.7696
05	0.01	balanced	0.0001	0.5623	0.7082	0.7681
06	100	balanced	0.0001	0.5644	0.7084	0.7697
07	1	none	0.01	0.4760	0.3624	0.7627
08	1	none	0.0001	0.4689	0.3499	0.7691

01: baseline; 02-03: C; 04-06: balanceo; 07: tolerancia; 08: repetición de 01. max_iter=1000 en todas. Las capturas de MLflow aparecen en los anexos.

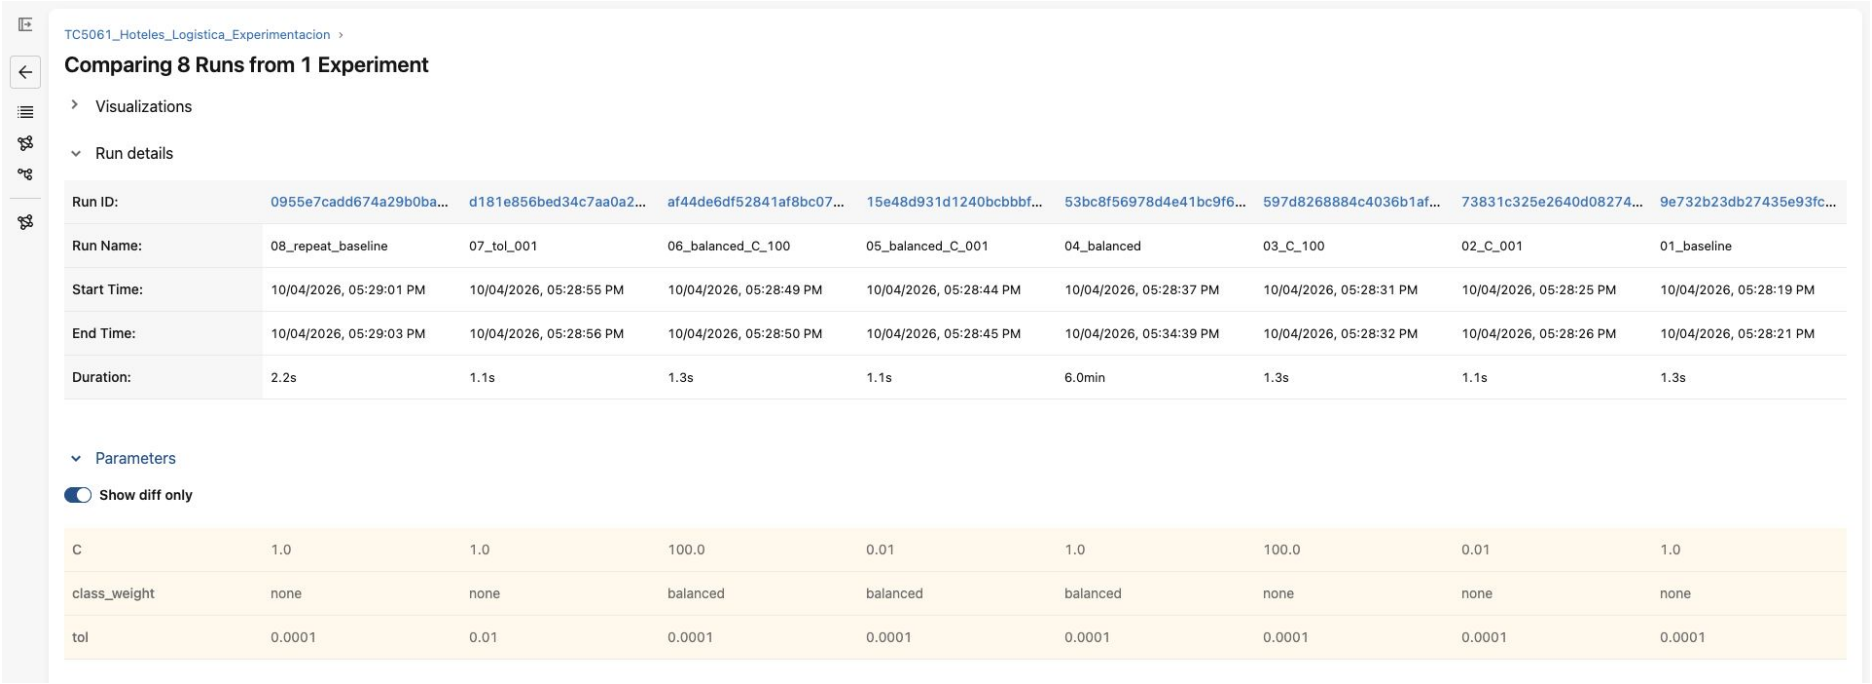
Fuentes: Hotel booking demand (Kaggle); MLflow sklearn; LogisticRegression (scikit-learn).

Anexo A. Ocho corridas: hiperparámetros y métricas de validación



Siete configuraciones diferentes y una repetición, agrupadas en el mismo experimento. La mayor F1 corresponde a 04_balanced; 01 y 08 tienen el mismo resultado.

Anexo B. Vista Compare: detalles y parámetros de las ocho corridas



TC5061_Hoteles_Logistica_Experimentacion ›

Comparing 8 Runs from 1 Experiment

Visualizations

Run details

Run ID:	0955e7cadd674a29b0ba...	d181e856bed34c7aa0a2...	af44de6df52841af8bc07...	15e48d931d1240bcbbbf...	53bc8f56978d4e41bc9f6...	597d8268884c4036b1af...	73831c325e2640d08274...	9e732b23db27435e93fc...
Run Name:	08_repeat_baseline	07_tol_001	06_balanced_C_100	05_balanced_C_001	04_balanced	03_C_100	02_C_001	01_baseline
Start Time:	10/04/2026, 05:29:01 PM	10/04/2026, 05:28:55 PM	10/04/2026, 05:28:49 PM	10/04/2026, 05:28:44 PM	10/04/2026, 05:28:37 PM	10/04/2026, 05:28:31 PM	10/04/2026, 05:28:25 PM	10/04/2026, 05:28:19 PM
End Time:	10/04/2026, 05:29:03 PM	10/04/2026, 05:28:56 PM	10/04/2026, 05:28:50 PM	10/04/2026, 05:28:45 PM	10/04/2026, 05:34:39 PM	10/04/2026, 05:28:32 PM	10/04/2026, 05:28:26 PM	10/04/2026, 05:28:21 PM
Duration:	2.2s	1.1s	1.3s	1.1s	6.0min	1.3s	1.1s	1.3s

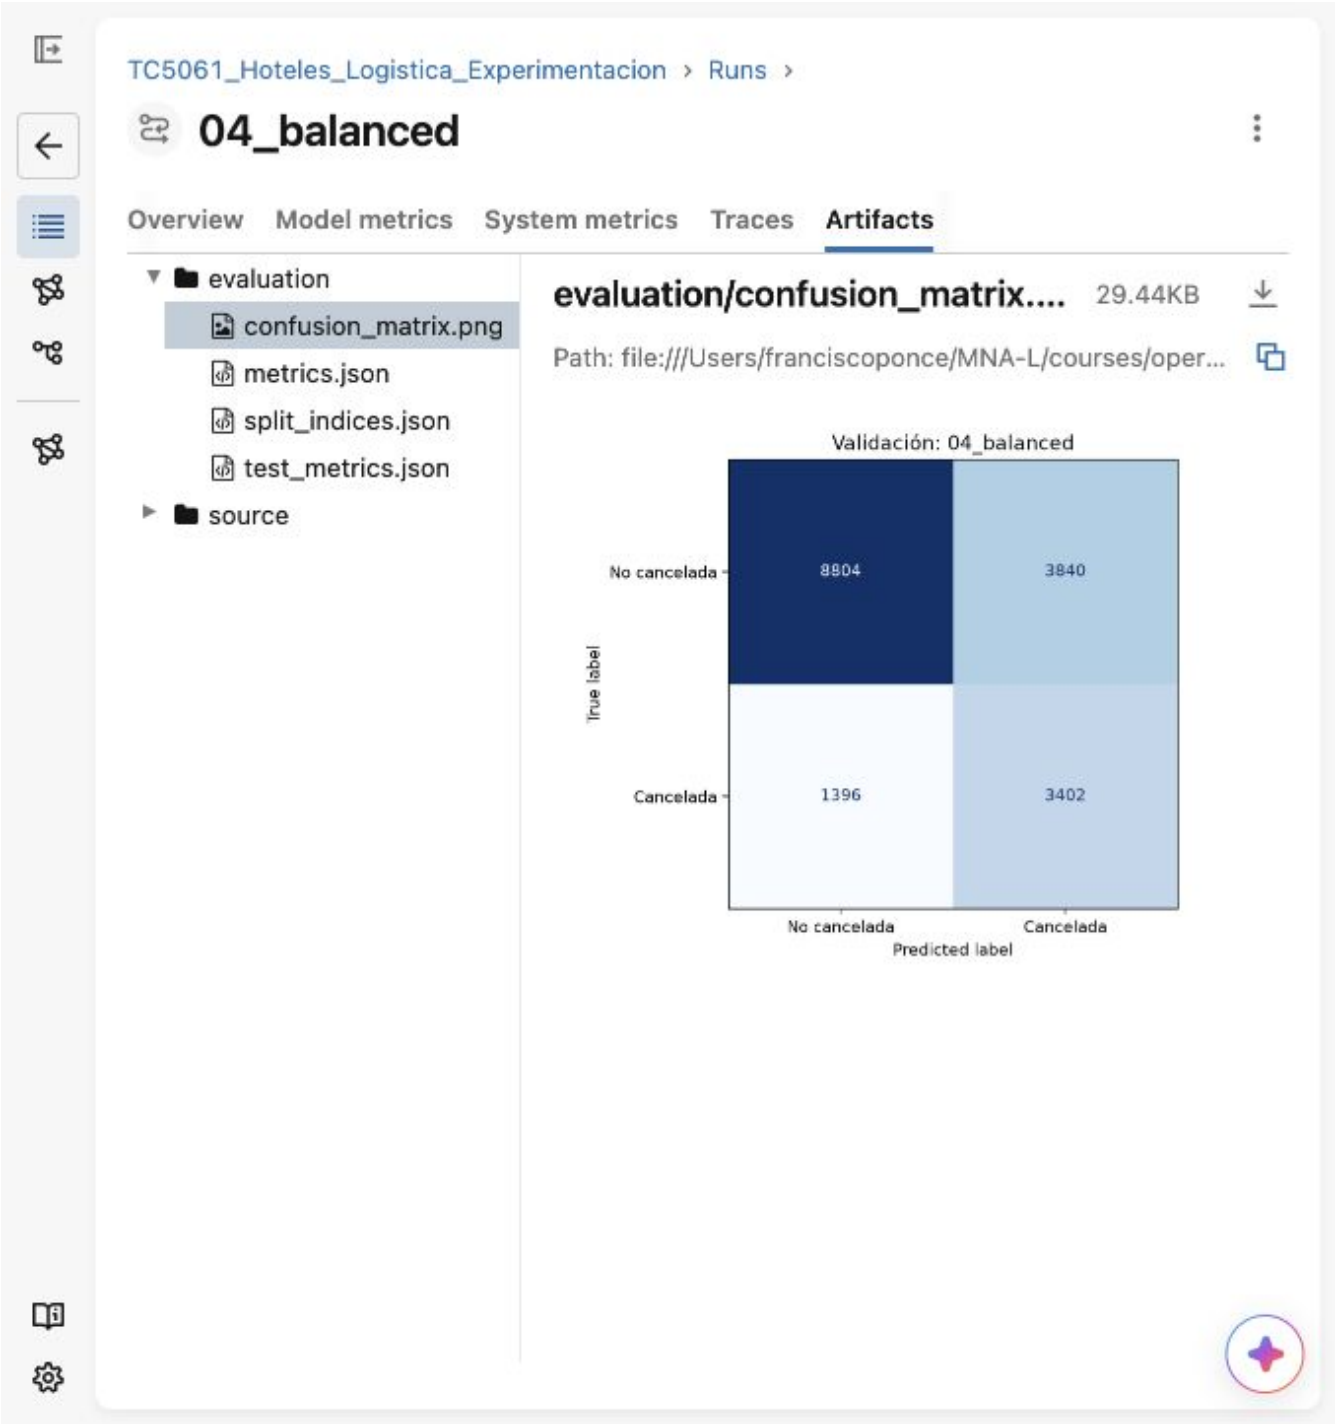
Parameters

Show diff only

C	1.0	1.0	100.0	0.01	1.0	100.0	0.01	1.0
class_weight	none	none	balanced	balanced	balanced	none	none	none
tol	0.0001	0.01	0.0001	0.0001	0.0001	0.0001	0.0001	0.0001

Vista Compare con Run details y Parameters abiertos. De izquierda a derecha: 08, 07, 06, 05, 04, 03, 02 y 01. Show diff only muestra C, class_weight y tol; las métricas de esas mismas corridas se muestran junto a los parámetros en el anexo A.

Anexo C. Detalle de 04_balanced y sus artefactos



Matriz de confusión de validación: TN=8,804; FP=3,840; FN=1,396; TP=3,402. También se registraron métricas JSON, índices de partición, código, dependencias y el pipeline completo mediante mlflow.sklearn.log_model.